

L'Évolution du Traitement de l'Information : Du SGBDR au Big Data

Résumé Exécutif

Ce document analyse la transition technologique des systèmes de gestion de bases de données relationnelles (SGBDR) traditionnels vers les architectures de Big Data. Historiquement conçus pour des besoins transactionnels (**OLTP**), les systèmes ont évolué pour répondre à des impératifs analytiques (**OLAP**) via l'informatique décisionnelle (**Business Intelligence**). Cependant, l'explosion du volume, de la vélocité et de la variété des données — les "3V" du Big Data — a rendu les structures rigides obsolètes. Le passage au Big Data s'appuie désormais sur des architectures distribuées (comme **Apache Hadoop**), le pattern **MapReduce** et des moteurs **NoSQL** , permettant de traiter des données non structurées et massives là où les systèmes classiques échouent.

1. Les Fondements : Du Transactionnel à l'Analytique

1.1 Le Modèle Relationnel et l'OLTP

Depuis les années 1980, le modèle relationnel, fondé sur l'algèbre relationnelle d'Edgar F. Codd, est le standard de structuration des données. Il est optimisé pour l' **OLTP** (*On-Line Transactional Processing*).

- **Objectif** : Gestion opérationnelle en temps réel (ex: modification de stock lors d'une facturation).
- **Performance** : Excellent pour les transactions courtes et fréquentes et les mises à jour.
- **Limites** : Inadapté pour l'analyse globale de tendances sur de grands volumes de données.

1.2 L'Émergence de l'OLAP

Pour répondre aux besoins statistiques, les structures ont évolué vers l' **OLAP** (*On-Line Analytical Processing*).

- **Approche Multidimensionnelle** : Utilisation de modèles en "étoile" ou en "flocon" stockés dans des entrepôts de données (*Data Warehouses*).
 - **Concepts clés** :
 - **Faits (ou mesures)** : Éléments métriques (montants, quantités).
 - **Dimensions** : Axes d'analyse (géographie, temps, catégories de produits).
 - **Utilité** : Agréger des résultats pour dégager des modèles statistiques et des tendances générales.
- | | | | | | | | | | | |
|---------------------------------|------|------|--|-------|--|-------|--|-------|--|-----------------|
| Caractéristique | OLTP | OLAP | | ----- | | ----- | | ----- | | Objectif |
| Besoins opérationnels | | | | | | | | | | |
| Analyse Business | | | | | | | | | | |
| Donnée | | | | | | | | | | |
| Petite taille, opérationnelle | | | | | | | | | | |
| Grande taille, historique | | | | | | | | | | |
| Modèle | | | | | | | | | | |
| Normalisé | | | | | | | | | | |
| Dénormalisé / Multidimensionnel | | | | | | | | | | |
| Requêtes | | | | | | | | | | |
| Courtes | | | | | | | | | | |
| Longues | | | | | | | | | | |
| Mises à jour | | | | | | | | | | |
| Fréquentes et courtes | | | | | | | | | | |
| Non fréquentes et discontinues | | | | | | | | | | |

2. Business Intelligence et Data Mining

L'informatique décisionnelle (BI) regroupe les outils collectant et modélisant les données brutes pour en faire des informations utiles à la stratégie de l'entreprise.

2.1 Le Data Mining (Exploration de données)

C'est un préalable à la BI qui utilise des algorithmes (statistiques, IA) pour extraire de la valeur depuis des tendances (*patterns*). Le processus suit quatre étapes :

1. **Sélection et échantillonnage** : Identification des données utiles.
2. **Transformation et nettoyage** : Adaptation des formats pour les algorithmes.
3. **Data Mining** : Génération des *patterns* .
4. **Évaluation** : Validation des modèles obtenus.

2.2 La Limite de la BI traditionnelle

Le problème majeur de la BI réside dans son incapacité à traiter les **données non structurées** (e-mails, vidéos, réseaux sociaux). Ces données sont qualifiées de *schema-less* (sans schéma prédéfini) et nécessitent les outils du Big Data.

3. Le Phénomène Big Data : Les 3V

Le Big Data traite les données qui échappent aux capacités des SGBDR traditionnels à cause de trois facteurs critiques :

- **Volume** : Capacité à traiter des masses de données colossales nécessitant un stockage modulable (*scalable*) et des requêtes distribuées.
- **Vélocité** : Vitesse de génération et de mise à jour des données (*streaming data*), exigeant des réponses en temps quasi-réel.
- **Variété** : Hétérogénéité des sources (logs serveurs, capteurs GPS, chats de réseaux sociaux).

4. Architectures et Solutions Techniques

4.1 Apache Hadoop et MapReduce

Hadoop est une architecture de traitement massif distribué qui répartit les données sur différents nœuds de calcul.

- **HDFS (Hadoop Distributed File System)** : Système de fichiers où les données sont chargées pour être accessibles aux nœuds.
- **Pattern MapReduce** :
- **Map (Distribution)** : Découpe la requête en sous-requêtes réparties sur plusieurs serveurs.
- **Reduce (Réduction)** : Agrège les résultats des sous-requêtes pour former le résultat final.
- **Avantage** : Permet une "montée en charge horizontale" en augmentant simplement le nombre de serveurs.

4.2 La Technologie NoSQL

Les moteurs NoSQL (ou SGBD non relationnels) ont été créés spécifiquement pour le Big Data. Contrairement aux SGBDR, ils ne reposent pas sur une logique de tables et déplacent la complexité du traitement vers le "code client" via des API.

Le Théorème CAP

Un système distribué ne peut garantir simultanément que deux de ces trois propriétés :

- **Cohérence (Consistency)** : Tous les nœuds voient la même donnée au même moment.

- **Disponibilité (Availability)** : Le système fonctionne même si un nœud tombe.
- **Résistance au morcellement (Partition tolerance)** : Le nœud fonctionne de manière autonome.

Modèles de données NoSQL

- **Clé/Valeur** : (ex: Redis, Riak) Simple paire identifiant/donnée, très rapide mais l'intelligence est portée par l'applicatif.
- **Orienté Colonne** : (ex: HBase, Cassandra) Nombre de colonnes dynamique par enregistrement, évitant les valeurs nulles.
- **Orienté Graphe** : (ex: Neo4J) Basé sur les nœuds et les relations, idéal pour les réseaux sociaux.
- **Données Non Structurées** : Souvent stockées en formats **JSON** ou **XML** après extraction.

5. Exemples d'Application

L'utilisation du Big Data est illustrée par les géants du web (Google, Facebook, Amazon) :

- **Recherche sur Facebook** : Lorsqu'une recherche est effectuée, la requête est distribuée et découpée sur plusieurs serveurs. Grâce à l'architecture distribuée et à la théorie des graphes, le système remonte instantanément le profil recherché ainsi que les profils associés (amis), malgré le volume colossal de données à parcourir.